

赛题五 / 招采数据智能分析引擎

技术路线与数据质量分析报告

解析方案、实测边界与评测计划

版本 0.1 · 2026-09-26 · 提交前草稿

评审口径

当前没有人工 Gold，也没有官方查询基准。官方数据上的候选、OCR 提示和吞吐记录只说明接入管线运行过，不能解释为准确率或评分结果。

一 结论与使用范围

本报告区分工程接入能力和抽取质量。官方全量任务证明 1038 条公告能够通过后台管线进入隔离数据库，并获得规则候选及 OCR 提示；由于任务使用 rules + RapidOCR、没有模型调用，也没有人工 Gold，它不能证明字段准确或场景查询与官方答案一致。

二 技术路线对比

方案	适用内容	速度/成本	主要风险
规则解析	明确 HTML/Office 表格、采购单位与标准标签	本地执行，不消耗模型额度；稳定且可追溯	正文自由叙述、扫描件和变化较大的版式覆盖有限
Qwen/DeepSeek 模型	非表格内容、上下文归并、结构化字段抽取	受服务时延、并发与 token 影响；每个文档需请求	幻觉、截断、端点参数差异及费用，需要证据校验
Hybrid	规则行与模型补充结果合并	兼顾确定性与语义覆盖，仍会产生模型调用	跨附件对齐与去重可能冲突；须保留证据并人工评测
RapidOCR + 表格映射	扫描图像、扫描 PDF 的文本入口	本机推理，不消耗云模型额度	识别文字不等于正确还原表格结构，必须抽样核验

当前建议的操作次序是先用规则模式建立可复现基线，再以人工 Gold 对比规则、模型和混合方案；留出集必须与调优样本隔离。全量部署时先核对源文件哈希与解析警告，遇到错误附件不得让模型臆造缺失字段。

三 数据接入与工程基线

指标	实测值	口径
公告数	1,038 / 1,038 完成; 0 最终失败	独立 SQLite 数据集, 模型调用 0 次
入口文件完整性	2,008 个文件 SHA-256 复核; 0 不匹配	源文件未修改
附件	970 个外层 ZIP, 合计约 3.57 GB; RAR/7z 解析出 239/13 个叶文件	递归解析共 14,174 个叶文件, 含 HTML
抽取候选	6,814 条标的候选; 采购参与方 0、中标记录 0	无 Gold, 不代表正确率
处理时间	3 个工作进程, 检查点估算约 66 分 45 秒; 每公告中位数 1.127 秒, P95 41.249 秒	rules + OCR 本机工程基线, 不代表 model/hybrid 模式
OCR 提示	2,261 条识别/复核提示覆盖 359 条公告	提示数量不是正确识别率

四 数据质量风险

发现	范围	处理状态
下载错误伪附件	87 个成员, 涉及 61 条公告	已识别并隔离; 缺失内容未恢复, 需数据方提供有效材料
OCR 与可信文本不足	2261 条 OCR 提示; 另 21 条无可信文本提示覆盖 16 条公告	应按分层样本回看原图和抽取结果
不支持格式	7 条格式警告, 覆盖 3 条公告	部分 WPS/专有格式需评估转换路径
PDF 流错误	7 条错误记录, 覆盖 6 条公告	需要人工核对文档能否重开或重新取得
压缩成员读取错误	1 个成员	源内容未恢复, 不能计作覆盖成功
参与/中标关系	全量规则候选库中均为 0	现已加入结构化投标表规则解析; 需人工验证再用于聚合

这些数据描述完整性、运行告警和候选产量, 不回答 TP/FP/FN。只有依据原文独立完成人工标注后, 才可以按 docs/EVALUATION.md 的本地口径计算指标, 并同时说明该口径与赛事官方定义的差异。

五 人工验证计划

- 使用已生成的 24 条分层标注任务包; 两位标注员先共同完成 6 条试标, 比较分歧并书面统一字段规则。
- 试标分歧解决后, 各自完成互不重叠的 9 条正式任务; Gold 逐条对照 HTML 与附件, 自动预测只作为参考候选。
- 统计标注一致性和遗漏类型; 保留留出样本, 在调优完成前不查看其模型指标。
- 在固定软件版本、模型名、采样参数和 endpoint 下, 对 rules、model、hybrid 使用完全相同的样本运行并导出报告。

5. 分别报告七字段、采购单位、投标主体、中标方/金额的精确率、召回率、F1 及约定的总体指标；按赛事正式公式复算后再填最终提交件。

六 局限与后续工作

- 官方附件有真实缺失与专有格式；无效材料不能靠 OCR 或模型恢复。
- 没有 Gold 时，不可以把开发集、合成夹具或模型自评分包装成赛事准确率。
- P1-1 结构化评审表抽取要重点检查采购单位/代理机构误识别、评审分数误作金额、排名误作中标状态及包号错配。
- 最终报告需要主办方提供指标定义、官方查询样例和评审文档模板后再冻结版本。