

赛题五 / 招采数据智能分析引擎

# 系统设计说明

采购公告解析、关系建模与可核验查询

版本 0.1 · 2026-09-26 · 提交前草稿

## 评审口径

当前没有人工 Gold，也没有官方查询基准。官方数据上的候选、OCR 提示和吞吐记录只说明接入管线运行过，不能解释为准确率或评分结果。

## 一 项目目标与范围

系统接收采购公告正文和附件，提取七项标的字段及采购单位、投标主体与中标关系，将原文证据随结果入库，再提供采购单位供应商、高频投标主体、共同投标和共同合作单位等查询。系统把自动输出视为候选，留有来源文件、位置与原文证据供人工核验。

| 输入                                           | 处理                                 | 输出                            |
|----------------------------------------------|------------------------------------|-------------------------------|
| HTML、DOC/DOCX、XLS/XLSX、可读 PDF、ZIP/RAR/7z 及图片 | 内容识别、归档展开、文本/表格解析、<br>可选 OCR 与模型抽取 | 采购单位、项目、采购包、投标主体、中标记录、标的候选及告警 |

## 二 业务与验收要求

- 每个字段保留来源文件及位置；未披露值保持空，不用常识补全。
- 区分投标参与、明确未中标、明确中标和结果未知；排名分数不能单独推断中标状态。
- 附件解析问题要可见：未匹配、内容错误页、不支持格式、OCR 无可信文本及解析异常都应提示。
- 查询按采购包建模；频次与金额定义以赛题正式字段说明和基准样例为最终口径。
- 原始官方材料不提交到代码仓库；运行数据库、模型凭据、演示账号留在本地忽略目录。

## 三 总体架构

前端使用 Vue 3/Vite；后端使用 FastAPI，按解析、抽取、持久化、关系查询及任务 API 分层；关系数据默认写入 SQLite。Neo4j 导出和查询代码独立于当前 API 主链路。

| 层   | 实现                                  | 边界                    |
|-----|-------------------------------------|-----------------------|
| 交互层 | 分析台、批处理任务页、独立人工标注页                  | 浏览器本地保存标注进度；任务数据包负责分发 |
| 服务层 | FastAPI API、单机后台任务、签名会话认证           | 评审账号是单账号演示模式，没有角色系统   |
| 解析层 | 按内容识别 DOC/XLS/PDF/Office/图片与压缩包     | 压缩大小、深度、成员数均设上限       |
| 抽取层 | 规则表格解析、可选 RapidOCR、可选 Qwen/DeepSeek | 模型和 OCR 输出都是候选，不代表金标  |
| 数据层 | SQLite 项目/包/实体/参与/中标/标的关系           | 每数据集独立数据库；官方数据隔离于默认库  |

## 四 数据模型

| 实体                 | 关键关系                                | 用途                    |
|--------------------|-------------------------------------|-----------------------|
| organizations      | 采购单位、供应商和投标主体共用组织实体；aliases 保留原名    | 保守归一名称，不因相似字符串自动合并法人  |
| projects           | 每条公告关联项目和采购单位                       | 项目编号、预算、公告成交总额分别保存    |
| packages           | 项目可含多个采购包/标段                        | 作为投标参与和查询频次的事件单元      |
| bid_participations | 主体关联采购包，记录 winner/nonwinner/unknown | 保存角色、包号、来源和原文证据       |
| awards             | 明确中标主体关联采购包                         | 保存主体级中标金额及证据，不以项目总额代替 |
| procurement_items  | 标的记录关联公告与采购包                        | 七字段、字段价格单位、来源定位及抽取方式  |

## 五 抽取和入库流程

1. 读取上传文件并依据内容特征识别真实格式；逐层展开归档，拒绝超过安全预算的成员。
2. 读取 HTML、Office、PDF、图片文本；符合配置时用本地 OCR 处理扫描内容。失败和不可信结果保留警告。
3. 规则解析采购单位、项目头字段、标的表格、投标人/资格审查表；如启用模型，再抽取非表格内容并与规则行对齐。
4. 规范化金额和包号，去除有证据支持的重复行；对歧义和冲突保留候选并警告，不用宽松别名或排名猜测结果。
5. 以每个公告为检查点写入独立数据集；任务支持暂停、续跑、重试与导出逐条报告。

## 六 访问控制与运行

本地开发默认不启用账号。演示部署可开启 AUTH\_ENABLED，以强密码和随机签名密钥创建单一评审账号；后端使用 HttpOnly、SameSite=Strict 的 HMAC 签名 Cookie，过期时间默认 8 小时。配置缺失时受保护 API 返回 503。账号配置和原始数据均不进入 Git。

后端环境使用 Python 3.11–3.13；前端使用 Node.js/npm。安装步骤见 README，评审账号配置、登录和演示边界见 docs/REVIEWER\_GUIDE.md。

## 七 测试与实测结果

| 验证项      | 当前证据                                   | 解释                                         |
|----------|----------------------------------------|--------------------------------------------|
| 后端回归     | 全量测试 183 passed、1 skipped；<br>Ruff 通过  | 覆盖解析、后台任务、评测、登录与离线<br>样例逻辑                 |
| 前端回归     | 11 passed；构建通过                         | 构建有 ECharts 大 chunk 提示，不影响<br>构建成功         |
| 官方数据全量接入 | 1038/1038 入库，0 最终失败；6,814<br>条标的候选     | rules + RapidOCR，调用模型 0 次；参<br>与主体/中标记录为 0 |
| 登录/离线演示  | 本机登录、查询、标注页 HTTP 200；3<br>条虚构公告及 5 个组织 | 不等于第二台评审设备网络验收                             |

## 八 限制与提交前确认

- 没有人工核验 Gold，因此不报告准确率、精确率或召回率。OCR 2261 条提示不代表识别正确。
- 当前官方数据规则全量没有投标参与和中标记录；P1-1 新加的结构化评审表解析需在 Gold 集上验证误报和漏报。
- 87 个无效下载附件、少量不支持格式、PDF 流错误和 1 个损坏成员仍需人工/数据方处理。
- Neo4j 不是当前在线 API 的关系查询后端；不可宣称线上场景使用 Neo4j 图检索增强。